Lab1 文本分类实验 · 朴素贝叶斯

01 / 基线、文本范围与特征对照

问题与实验设置

检验头部信息及词频表示是否改善分类。数据为课程提供的 CSV：7368 条有标签文本、10 类（每类705-747条），2457 条无标签测试文本。先以 SEED=42 分层划分5894/1474（80/20），再仅在训练部分拟合词表与 IDF。accuracy 为预先锁定主指标，macro-F1 为辅指标；类别只用数字标签。

原理与控制变量

MultinomialNB 采用类别条件下特征独立假设，alpha=1 作平滑；TF-IDF 是非负加权特征，但不完全等同词频计数假设。A0 为向量器全默认：小写、词级一元组、L2归一化、无限词表。A/B各次仅改表中一个因素；诊断对象不保存。

方案（其余参数固定）	特征数	训练 Acc	验证 Acc	验证 F1
全文 A0	99901	0.9739	0.8982	0.8984
仅正文 A1	96513	0.9662	0.8847	0.8848
仅头部 A2	16975	0.9379	0.7510	0.7481
英文停用词 B1b	99595	0.9818	0.9193	0.9195
对数词频 B2b	99901	0.9776	0.9016	0.9020
词/二元词组 B3b	723275	0.9912	0.9009	0.9009

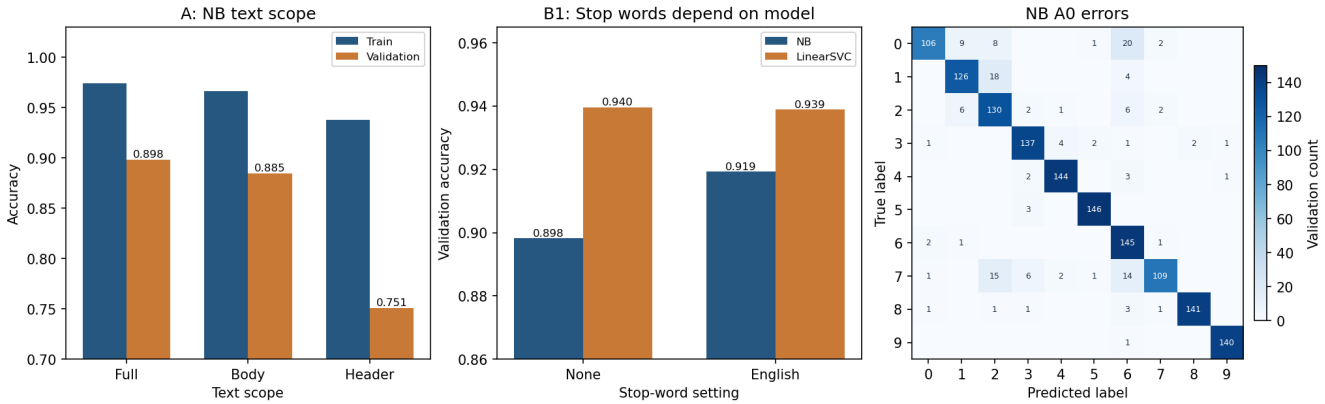


图1：训练/验证文本范围对照、停用词跨模型效应及NB验证混淆；矩阵行是真值，列是预测。

结果与误差（实测 / 推断）

NB A0 的训练/验证差为0.0756，验证错150条；0→6有20条、1→2有18条。英文停用词将NB验证Acc提高0.0210，而SVM变化为−0.0007，说明结论依赖模型。仅头部仍达0.7510，但训练/验证差增至0.1869。由此推断头部含可利用关联信息，不能证明跨来源泛化。

原文定性检视

错例索引431（0→6）：标题提到地球图像，正文主要讨论版权、转载与商业使用。这是可回查个案的解释假设，未验证错误的因果机制；8个代表性错例见qualitative_error_review.json。

思考3：其他表示与局限

词袋可直接保留计数；Word2Vec可得到静态语义向量，BERT可表示上下文语义（任务书给出的扩展方向）。本实验未实现后二者，不能声称它们更优。二元组使词表增至723275，而NB仅提升0.0027，提示应同时考虑精度与复杂度。

Lab1 文本分类实验 · 线性支持向量机

02 / 参数交互、稳健性与最终提交

原理与选参

LinearSVC 用线性决策函数、L2正则、squared_hinge损失及OvR多分类；C越大正则越弱。它与SVC(linear)默认损失/多分类策略不同。D1固定A0扫描C={0.1,1,10,100}；F1显式登记为两因素2×3交互网格。沿用验证Acc优先、同分比macro-F1、再选更简单候选的规则。

最终方案（实测）

现有51行记录去重比较，选全文TF-IDF sublinear_tf=True、C=1；验证Acc=0.945047，macro-F1=0.944995，训练/验证差=0.0548。全部7368条重新拟合Pipeline（107882维），再按测试原顺序预测；2457×1、0-9整数、无表头/索引三项断言及顺序检查通过。测试真实标签未知。

TF-IDF / C	训练 Acc	验证 Acc	验证 F1	迭代数
A0 / 1	0.9998	0.9396	0.9397	40
A0 / 10	1.0000	0.9396	0.9398	293
A0 / 100	1.0000	0.9403	0.9404	1504
B2b / 1	0.9998	0.9450	0.9450	40
B2b / 10	1.0000	0.9437	0.9436	280
B2b / 100	1.0000	0.9430	0.9429	1571

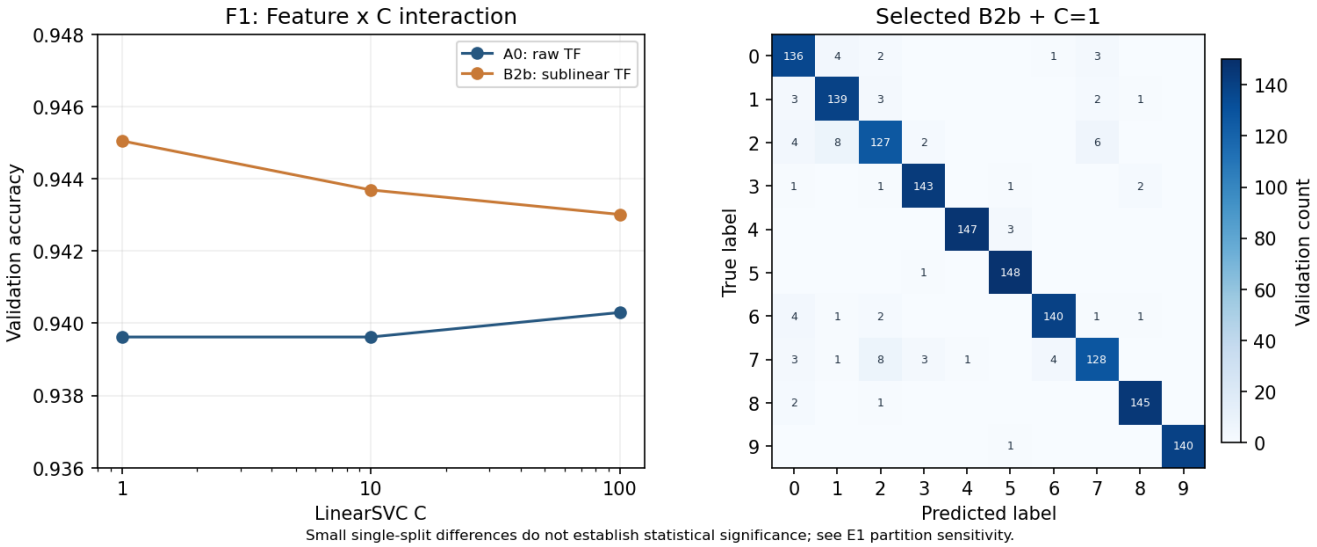


图2：F1网格的方向变化及选定SVM的验证混淆；小幅单次划分差异不构成显著性结论。

交互、误差与稳健性

A0在C=100略高，B2b在C=1最高；直接拼装B2b+C=100为0.943012，低于0.945047。E1中B2b相对A0在4/5种子提高、1/5打平；跨种子标准差0.0057-0.0089只是描述量，未做显著性检验，也未跨种子验证完整F1。验证诊断模型错81条；索引67（2→1）：正文讨论DOS安装、磁盘压缩及内存，软件和硬件词汇交叉。E2两比例的模型排序一致，但划分嵌套，证据非独立。

思考1：为何线性模型有效

A0有99901维、约99.84%稀疏；线性模型可在稀疏特征上学习类别区分权重，正则约束容量。相同A0下SVM/LR/NB验证Acc为0.9396/0.9186/0.8982；这是本实验支持线性模型的证据，不能外推到所有文本数据。

思考2：MLP结构、正则及风险

固定20次迭代预算，(100,)/(200,)/(100,50)验证Acc为0.9349/0.9342/0.9322，训练Acc均为1.0；alpha=1e-3仅提高到0.9362，未明显缩小差距。全部未收敛，扩大结构在此预算下无收益；更多迭代、早停或降维可能改变结果，尚未验证。首层约1000万参数，高于线性模型的约100万权重。

结论与证据边界

对数词频与参数交互是有实测对照的探索；验证集多次参与选择，最高分存在选择偏差。报告仅用NB/SVM各一页，其他模型作为扩展证据。课程原PDF物理第16页要求≤5页；按WORKFLOW记载的教师后续≤2页更新执行，该更新为用户转述、未独立核验。