当代人工智能作业三 · CIFAR-10 图像分类

GitHub 仓库 https://github.com/oceancat91/AI-Lab

数据、模型与训练方案

在 CIFAR-10 上比较普通 CNN 与残差 CNN，考察随机裁剪和翻转能否改善泛化。验证集选出的配置 D 在官方测试集上正确分类 8498/10,000 张图像，准确率为 84.98%。

数据划分与预处理

输入为 32×32 RGB 图像。以种子 42 对官方训练集逐类抽样，每类取 4,500 张训练、500 张验证，共 45,000 / 5,000 张。官方测试集含 10,000 张图像，仅在冻结最终模型后评估。

将像素缩放至 [0, 1]，按训练子集的 RGB 均值（0.4918, 0.4825, 0.4468）和标准差（0.2471, 0.2435, 0.2617）统一标准化。增强组仅在训练时反射填充 4 像素、随机裁回 32×32，并以 0.5 概率水平翻转。

网络与优化

阶段	操作	输出（通道×高×宽）
卷积块 1	3×3 卷积，通道 3→16→16，再池化	16×16×16
卷积块 2	3×3 卷积，通道 16→32→32，再池化	32×8×8
卷积块 3	3×3 卷积，通道 32→64→64，再池化	64×4×4
分类头	全局平均池化，64 维向量映射至 10 类	10 个 logits

普通 CNN 的每块含两次卷积与 BatchNorm，ReLU 激活后以 2×2 最大池化降采样。残差 CNN 在第二次 BatchNorm 后加入 1×1 卷积与 BatchNorm 的投影支路，相加后再激活、池化。两种网络均从头训练，参数量分别为 72,954 和 75,786。

四组共用划分与训练预算。用交叉熵、SGD、动量 0.9、权重衰减 0.0005、批大小 256 训练 20 轮。前两轮学习率为 0.05、0.1，随后余弦衰减至 0.001。每轮结束在验证集评估，按准确率最高、损失最低、轮次最早保留检查点。实测采用 Ryzen 5 5600H CPU、FP32 和 6 个计算线程。

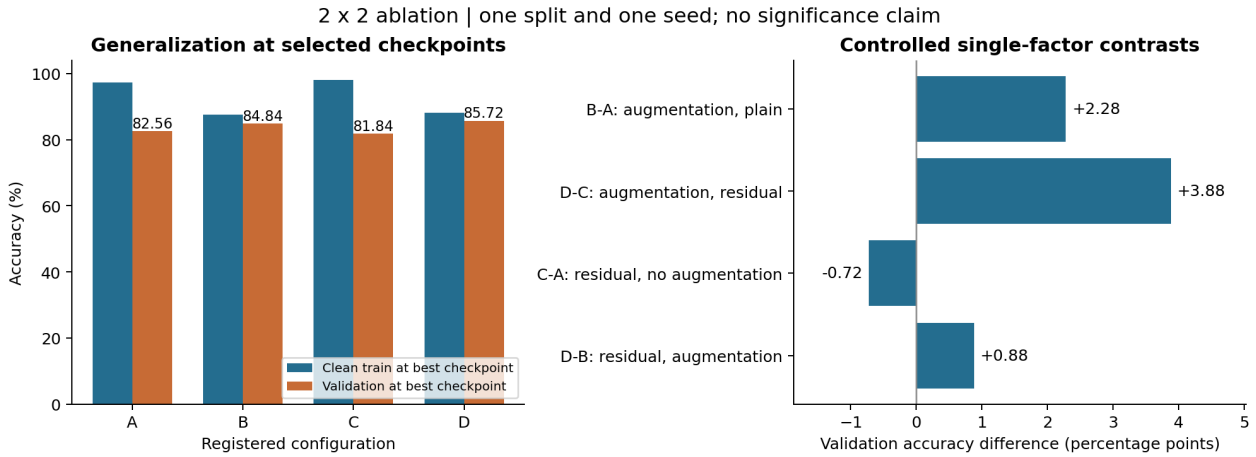


图 1 加入增强后，普通和残差 CNN 的验证准确率分别提高 2.28、3.88 个百分点。换成残差结构后，无增强时变化为 -0.72、有增强时为 +0.88 个百分点。

四组对照与训练曲线

配置	架构 / 增强	最佳轮	训练准确率[1]	验证准确率	用时（分）
A	plain / none	20	97.25%	82.56%	11.3
B	plain / crop_flip	19	87.58%	84.84%	11.0
C	residual / none	19	98.06%	81.84%	11.9
D	residual / crop_flip	19	88.07%	85.72%	11.2

[1] 训练准确率以各组最佳检查点在完整、无增强的训练集上测得。图 2 的训练曲线记录训练模式下逐批更新时的在线指标。

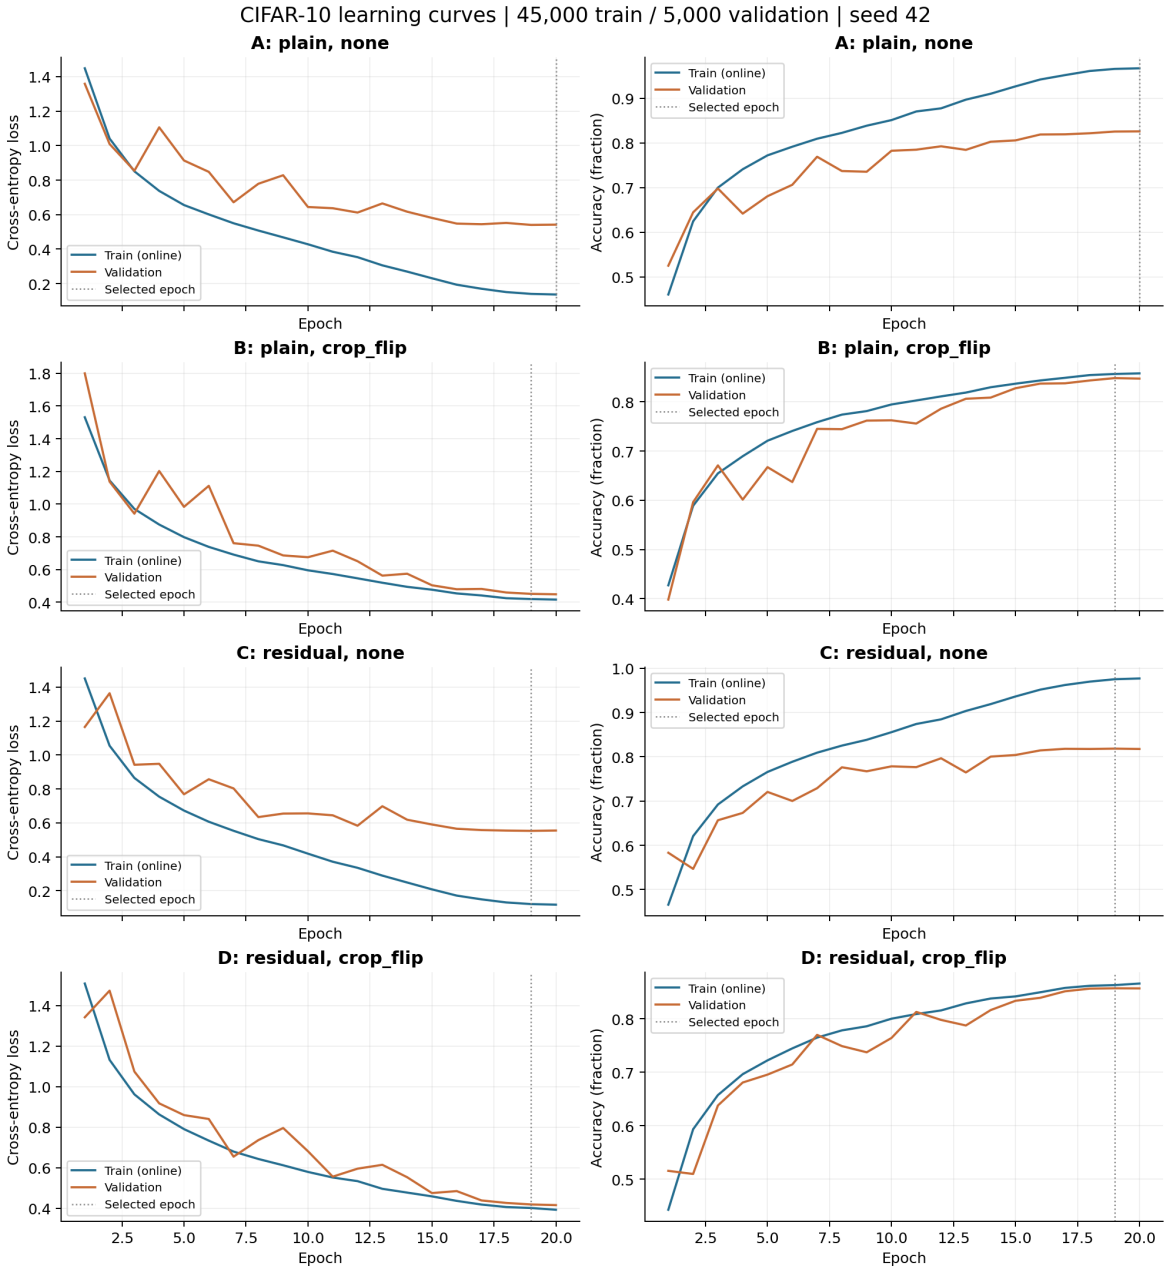


图 2 四组各 20 轮的交叉熵和准确率。每行对应一组，横轴为轮次，两条线分别为训练集与验证集。

A、C 的训练与验证准确率分别相差 14.69、16.22 个百分点，B、D 的差距缩至 2.74、2.35 个百分点。无增强组后期仍在拟合训练集，验证准确率在约 82% 处趋缓，增强组的表现与减轻过拟合的解释一致。早期验证损失波动较大，后期趋稳。

测试集表现与逐类准确率

配置 D 第 19 轮的验证准确率为 85.72%。冻结后在官方测试集上正确分类 8498/10,000 张，总准确率 84.98%，交叉熵 0.4420，macro-F1 为 0.8487。准确率的 Wilson 95% 区间为 84.27% 至 85.67%，反映测试样本的抽样不确定性。

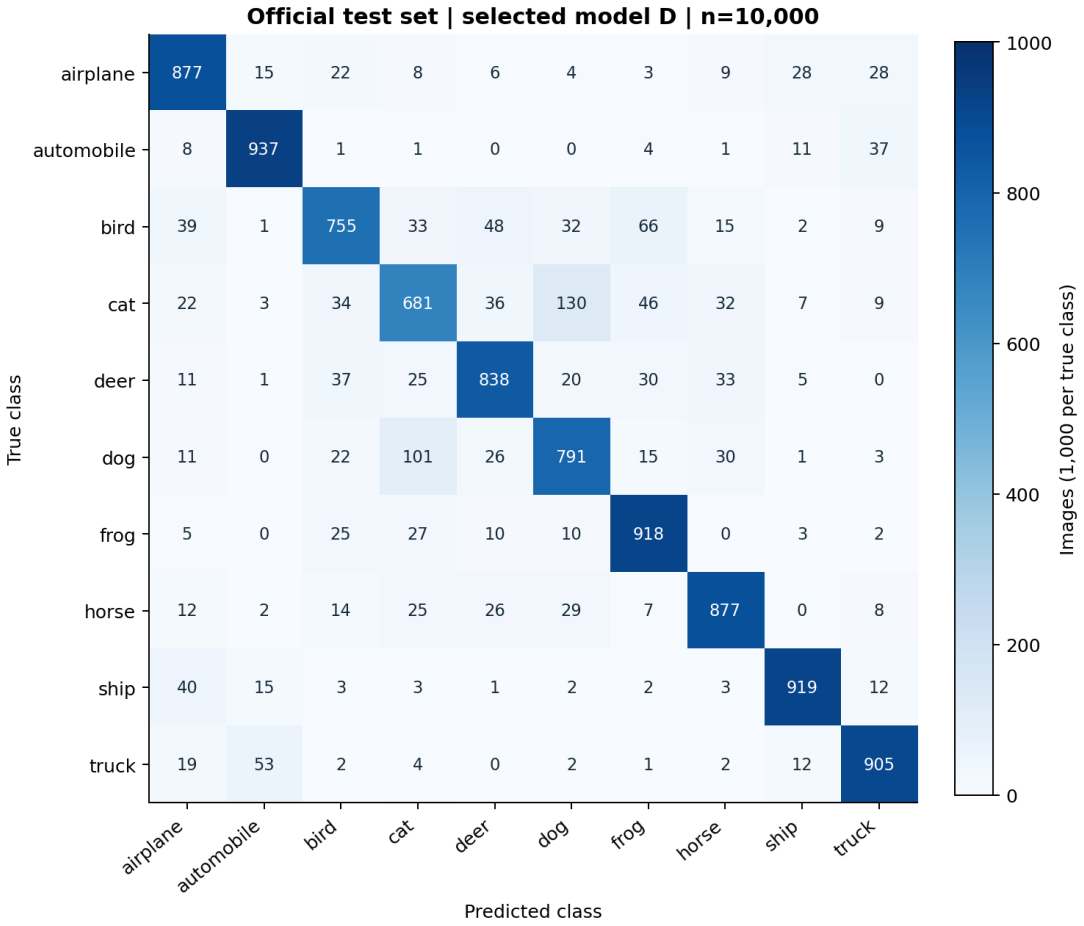


图 3 混淆矩阵。行是真实类别，列是预测类别，单元格给出样本数。

真实类别	正确数 / 样本数	逐类准确率	精确率	F1
airplane	877 / 1000	87.70%	0.840	0.858
automobile	937 / 1000	93.70%	0.912	0.925
bird	755 / 1000	75.50%	0.825	0.789
cat	681 / 1000	68.10%	0.750	0.714
deer	838 / 1000	83.80%	0.846	0.842
dog	791 / 1000	79.10%	0.775	0.783
frog	918 / 1000	91.80%	0.841	0.878
horse	877 / 1000	87.70%	0.875	0.876
ship	919 / 1000	91.90%	0.930	0.925
truck	905 / 1000	90.50%	0.893	0.899

每类准确率等于该类正确数除以该类样本数，即召回率。十类各有 1,000 张，总准确率等于十个逐类准确率的平均值。汽车最易识别，猫最难识别。下一页用完整混淆计数与具体图像分析误差。

误分类样本与常见混淆

数量最多的五种有向错误

真实类别	预测类别	误分张数	占该真实类别全部错误
cat	dog	130	40.75%
dog	cat	101	48.33%
bird	frog	66	26.94%
truck	automobile	53	55.79%
bird	deer	48	19.59%

猫被识别为狗 130 次，狗被识别为猫 101 次，共 231 次。猫的逐类准确率为 68.10%。32×32 图像中的毛色、轮廓和姿态可能相近，值得在这两组错误里进一步检验。

每一类中最有把握的错误



图 4 每个官方真实类别选取预测置信度最高的错误，同分取最小测试索引。图中标出索引、标签、预测和置信度。

#9227（汽车→卡车）与 #5416（卡车→汽车）都保留了相似的车辆轮廓。#5292（鹿→马）、#5642（狗→鹿）、#9635（马→鹿）中的四足动物仅占少量像素，耳部和四肢细节难以辨认。

#2532 和 #7559 的官方标签分别为飞机和船，图像却都呈现类似车头的轮廓。#2226（鸟→蛙）主体带褐色斑纹，#4786（蛙→猫）可见猫耳样轮廓，#2405（猫→蛙）主体呈绿色。外观与标签的差异使这些个例的成因难以判定。

用 torchvision 独立解码全部 10,000 张测试图像后，像素、标签和类别名均与自写加载器一致。所有样本按官方标签计分。每类最高置信错误刻画的是极端个案，其余错误的分布应结合上表判断。

Grad-CAM 解释与复现

对图 4 按类别顺序排列的前四个误例，取预测类别的 logit 对最后一层卷积的 8×8 特征图求梯度。将梯度空间均值作为通道权重，加权求和、取 ReLU 并归一化，双线性上采样至 32×32。

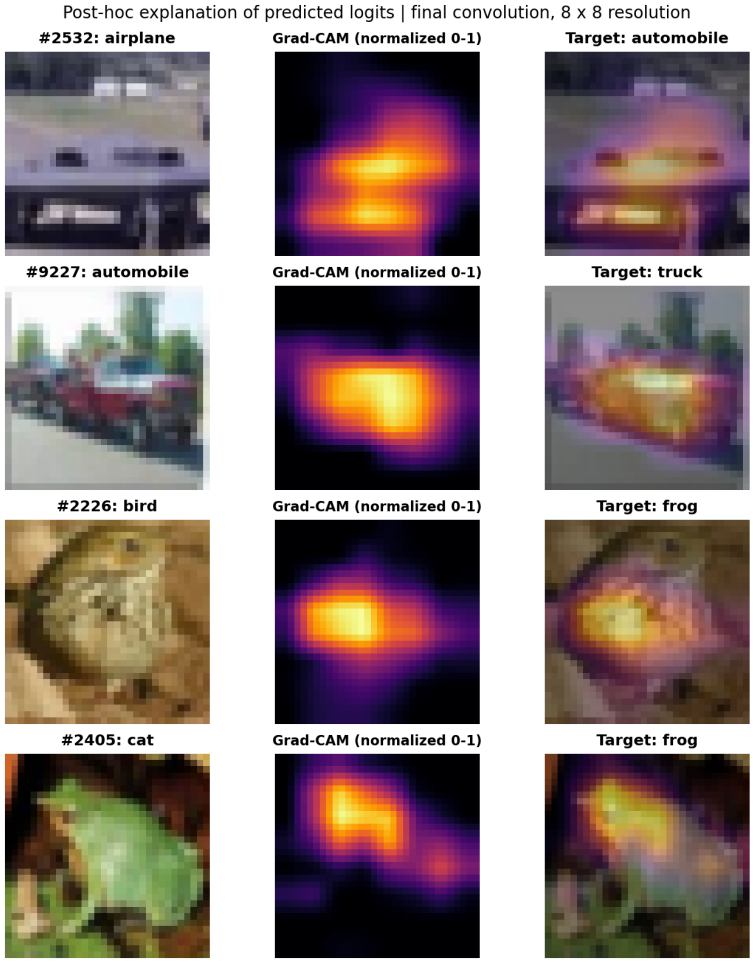


图 5 从左至右依次为带官方标签的图像、预测类别的 Grad-CAM 热图、热图与原图的叠加。

#2532 的汽车响应集中在画面中下部的车头样轮廓，#9227 的卡车响应覆盖中央车体。#2226 的蛙响应集中于圆形主体中央，#2405 的蛙响应从绿色主体上部延伸至右下。

这些位置显示了预测分数与局部特征的梯度关联。8×8 热图的空间分辨率限制了部件级解释，检验某个区域对判断的作用还需遮挡对照。

实验局限与复现

单次划分和种子限制了比较的精度。残差投影增加了参数量，余弦调度由四组共享。后续可固定参数预算、重复多个种子，检验有增强时的残差收益。

按仓库 README 创建 conda 环境后，运行 python reproduce.py --mode full 可重做四组实验。results/tables/ 保存 80 轮训练记录及 10,000 行测试预测。独立环境已复算划分、标准化统计量和预测指标，并重放四步合成数据训练。

参考资料

CIFAR-10 数据集 / He 等 · 残差网络 / Selvaraju 等 · Grad-CAM / PyTorch 分类教程